

BÁO CÁO THỰC HÀNH LAB5

Sinh viên	Bùi Thị Thanh Tuyền
MSSV	24521956
Lớp	DS108.Q21.2

1. Mục tiêu và phạm vi thực hiện

Bài thực hành được triển khai nhằm khảo sát hai phương pháp phân cụm không giám sát: K-Means và Gaussian Mixture Model (GMM). Với ba bài đầu, dữ liệu được sinh từ các phân phối Gaussian hai chiều để quan sát trực tiếp ảnh hưởng của khởi tạo ngẫu nhiên, sự mất cân bằng kích thước cụm và hình dạng phân phối. Hai bài sau mở rộng sang GMM, trong đó GMM được dùng để mô hình hóa covariance của từng cụm và áp dụng vào bài toán lọc nền ảnh.

Trong quá trình huấn luyện, các thuật toán không sử dụng nhãn thật của dữ liệu. Nhãn sinh dữ liệu chỉ được dùng sau khi huấn luyện để đối chiếu và tính accuracy tham khảo. Vì nhãn cụm do thuật toán sinh ra có thể bị đảo thứ tự, báo cáo sử dụng ánh xạ nhãn tốt nhất trước khi tính accuracy.

1.1. Yêu cầu đề bài

Phần	Yêu cầu c
K-Means 1	200 - 200 - 200, cùng Sigma
K-Means 2	1200 - 200 - 1000, cùng Sigma
K-Means 3	200 - 200 - 200, Sigma2 = $[[10,0],[0,1]]$ cho cụm thứ ba
GMM 1	Cài đặt GMM bằng NumPy và train bằng EM
GMM 2	Dùng GMM để lọc nền ảnh

2. Cấu trúc chương trình

Chương trình được tổ chức thành nhiều file độc lập để dễ kiểm tra và mở rộng. Các class chính được đặt trong thư mục src, còn mỗi bài thực hành có một file main riêng để chạy thí nghiệm. Cách tách này giúp phần thuật toán, phần sinh dữ liệu, phần trực quan hóa và phần lưu kết quả không bị trộn lẫn trong cùng một file.

File	Thành phần chính	Vai trò
kmeans.py	KMeans	Cài đặt K-Means bằng NumPy: khởi tạo tâm, gán nhãn, cập nhật tâm và tính inertia.
gmm.py	GMM	Cài đặt GMM bằng EM: E-step, M-step, log-likelihood và dự đoán cụm.
data_generator.py	DataGenerator	Sinh dữ liệu Gaussian cho các bài 1, 2 và 3.
image_filter.py	ImageFilterGMM	Biến ảnh thành tập pixel RGB và dùng GMM để tách nền.
main_assignment*.py	run()	Chạy riêng từng bài, lưu hình minh họa và file kết quả.

3. Cơ sở thuật toán

3.1. K-Means

K-Means biểu diễn mỗi cụm bằng một tâm cụm. Ở mỗi vòng lặp EM, thuật toán thực hiện hai bước: gán mỗi điểm dữ liệu vào tâm cụm gần nhất theo khoảng cách Euclidean, sau đó cập nhật lại tâm cụm bằng trung bình các điểm đã được gán vào cụm đó. Đại lượng được tối ưu là tổng bình phương khoảng cách từ điểm đến tâm cụm, còn gọi là inertia hoặc WCSS.

Ưu điểm của K-Means là đơn giản, dễ hiện thực và chạy nhanh. Tuy nhiên, thuật toán nhạy với khởi tạo tâm cụm, nhạy với sự mất cân bằng kích thước cụm và thường hoạt động tốt nhất khi các cụm có dạng gần hình cầu. Khi dữ liệu có cụm bị kéo dài hoặc có covariance khác nhau rõ rệt, ranh giới phân cụm của K-Means dễ bị lệch.

3.2. Gaussian Mixture Model

GMM giả sử dữ liệu được tạo ra từ hỗn hợp nhiều phân phối Gaussian. Mỗi thành phần Gaussian có trọng số, vector trung bình và ma trận covariance riêng. Do học được covariance của từng cụm, GMM linh hoạt hơn K-Means trong trường hợp cụm có hình dạng elip hoặc độ phân tán khác nhau theo từng hướng.

Trong EM của GMM, E-step tính xác suất mềm cho biết một điểm thuộc về từng thành phần Gaussian. M-step cập nhật trọng số, mean và covariance dựa trên các xác suất mềm đó. Log-likelihood được dùng để theo dõi quá trình hội tụ: khi giá trị này thay đổi rất nhỏ giữa hai vòng lặp liên tiếp, thuật toán xem như đã ổn định.

4. Tổng hợp kết quả thực nghiệm

Bài	Thuật toán	Chỉ số chính	Kết quả	Ý nghĩa
1	K-Means	Accuracy / Inertia	98.50% / 1121.84	Cụm cân bằng, tách rõ.
2	K-Means	Accuracy / Inertia	97.71% / 4536.40	Cụm 200 điểm dễ kém ổn định.
3	K-Means	Accuracy / Inertia	89.83% / 1985.32	Cụm elip làm giảm độ chính xác.
4	GMM	Accuracy GMM	96.17%	GMM học được covariance riêng.
5	GMM ảnh	Thành phần nền	Component 1	Tách nền theo phân bố màu RGB.

Các chỉ số cho thấy K-Means hoạt động tốt ở bài 1 và vẫn đạt kết quả khá cao ở bài 2 do các cụm còn tương đối tách biệt. Tuy nhiên, bài 2 cho thấy cụm nhỏ nhạy cảm hơn khi kích thước cụm không cân bằng, còn bài 3 làm rõ hạn chế của K-Means với cụm có dạng elip. Ở bài 4, GMM cho kết quả tốt hơn do có khả năng học covariance riêng cho từng cụm. Ở bài 5, GMM được áp dụng theo hướng khác: thay vì phân cụm điểm hai chiều, mỗi pixel ảnh được xem là một điểm dữ liệu trong không gian màu RGB.


5. Phân tích từng bài

5.1. Bài 1 - K-Means với ba cụm cân bằng


Yêu cầu của bài 1 là sinh 600 điểm dữ liệu từ ba phân phối Gaussian có cùng covariance và cùng số lượng điểm. Đây là trường hợp tương đối thuận lợi cho K-Means vì các cụm có kích thước cân bằng, độ phân tán tương tự nhau và vị trí trung tâm khác biệt khá rõ.

Kết quả tốt nhất trong các lần chạy đạt accuracy 98.50%, inertia 1121.84 và hội tụ sau 4 vòng lặp. Số điểm trong ba cụm dự đoán lần lượt là [201, 199, 200], gần tương ứng với cấu trúc 200-200-200 của dữ liệu sinh ra.


Nhận xét: khởi tạo ngẫu nhiên vẫn có ảnh hưởng đến K-Means, vì các tâm cụm ban đầu khác nhau có thể dẫn đến nghiệm cục bộ khác nhau. Tuy nhiên, ở bộ dữ liệu này, ba cụm tách biệt tốt nên đa số lần khởi tạo vẫn hội tụ về nghiệm hợp lý. Trường hợp này cho thấy K-Means phù hợp khi dữ liệu gần với giả định cụm tròn, cân bằng và ít chồng lấn.



Hình 1.1. Dữ liệu gốc bài 1



Hình 1.2. Kết quả K-Means bài 1




Hình 1.3. Inertia của K-Means bài 1 qua nhiều lần khởi tạo

5.2. Bài 2 - K-Means với kích thước cụm không cân bằng


Bài 2 thay đổi số lượng điểm giữa các cụm: 1200 điểm, 200 điểm và 1000 điểm. Đây là tình huống khó hơn bài 1 vì dữ liệu không còn cân bằng; cụm 200 điểm nhỏ hơn đáng kể so với hai cụm còn lại, nên kết quả K-Means có thể nhạy hơn với cách khởi tạo centroid.

Kết quả thực nghiệm đạt accuracy 97.71%, inertia 4536.40 và hội tụ sau 6 vòng lặp. Số điểm trong các cụm dự đoán là [202, 1192, 1006]. Phân bố này vẫn tương đối gần với cấu trúc dữ liệu sinh ra, nhưng cụm nhỏ có xu hướng nhạy cảm hơn với vị trí khởi tạo tâm cụm so với hai cụm lớn.


Nhận xét: sự mất cân bằng kích thước cụm làm cụm nhỏ 200 điểm dễ kém ổn định hơn, đặc biệt khi tâm cụm ban đầu không rơi gần vùng dữ liệu của cụm này. Trong thí nghiệm này, các cụm vẫn khá tách biệt nên accuracy còn cao; tuy nhiên nếu khoảng cách giữa các cụm giảm hoặc dữ liệu nhiều hơn, K-Means sẽ dễ ưu tiên giảm sai số cho hai cụm lớn và làm giảm chất lượng mô tả cụm nhỏ.



Hình 2.1. Dữ liệu gốc bài 2



Hình 2.2. Kết quả K-Means bài 2




Hình 2.3. Inertia của K-Means bài 2 qua nhiều lần khởi tạo

5.3. Bài 3 - K-Means với một cụm bị kéo dài


Bài 3 giữ số lượng điểm cân bằng nhưng thay covariance của cụm thứ ba thành ma trận có phương sai lớn theo trục x. Về mặt hình học, cụm này không còn có dạng tròn mà bị kéo dài theo phương ngang. Đây là trường hợp thường làm lộ hạn chế của K-Means.

Kết quả K-Means đạt accuracy 89.83%, inertia 1985.32 và hội tụ sau 5 vòng lặp. Số điểm trong các cụm dự đoán là [203, 147, 250], lệch khỏi cấu trúc 200-200-200. Điều này cho thấy thuật toán đã phân chia lại một phần của cụm kéo dài sang các cụm lân cận.


Nhận xét: K-Means sử dụng khoảng cách Euclidean đến tâm cụm, nên ranh giới phân cụm có xu hướng phù hợp với các cụm tròn hơn là cụm elip. Với cụm có covariance lớn theo một hướng, các điểm ở phần đuôi của cụm có thể gần tâm cụm khác hơn tâm thật của chúng. Vì vậy, K-Means dễ xảy ra hiện tượng “cắt đuôi” cụm kéo dài, làm giảm chất lượng phân cụm dù số lượng cụm K đã đặt đúng.



Hình 3.1. Dữ liệu gốc bài 3



Hình 3.2. Kết quả K-Means bài 3




Hình 3.3. Inertia của K-Means bài 3 qua nhiều lần khởi tạo

5.4. Bài 4 - Gaussian Mixture Model và so sánh với K-Means


Bài 4 hiện thực GMM bằng NumPy và huấn luyện bằng EM. Thực nghiệm được đặt trên dữ liệu có một cụm bị kéo dài để so sánh trực tiếp với K-Means. Đây là lựa chọn phù hợp vì GMM có khả năng học covariance của từng thành phần, trong khi K-Means chỉ mô tả mỗi cụm bằng một tâm.

Trên cùng dữ liệu, K-Means đạt accuracy 89.83%, còn GMM đạt accuracy 96.17%. Số điểm trong các cụm của GMM là [199, 197, 204], gần hơn với cấu trúc 200-200-200 so với K-Means. Log-likelihood cuối cùng của GMM là -2515.71, sau 35 vòng lặp.


Nhận xét: GMM cho kết quả tốt hơn vì không ép cụm phải có dạng tròn. Khi học covariance riêng cho từng cụm, GMM có thể mô tả cụm kéo dài theo trục x một cách tự nhiên hơn. Ngoài ra, việc dùng xác suất mềm trong E-step giúp các điểm gần ranh giới không bị gán quá cứng ngay từ đầu, làm quá trình cập nhật tham số ổn định hơn trong những trường hợp dữ liệu có chồng lấn nhẹ.



Hình 4.1. K-Means trên dữ liệu bài 3



Hình 4.2. GMM trên cùng dữ liệu



Hình 4.3. Log-likelihood của GMM trong quá trình huấn luyện

5.5. Bài 5 - Lọc nền ảnh bằng GMM

Bài 5 áp dụng GMM cho ảnh. Thay vì xem dữ liệu là các điểm hai chiều, mỗi pixel ảnh được chuyển thành một điểm trong không gian màu RGB. GMM sau đó phân cụm các pixel thành nhiều nhóm màu. Với ảnh con bò trên nền cỏ, nhóm nền thường chiếm số lượng pixel lớn và có thành phần màu xanh nổi bật hơn các nhóm còn lại.

Kết quả phân cụm pixel cho thấy component 0: 6258 pixel (10.64%), component 1: 51136 pixel (86.97%), component 2: 1406 pixel (2.39%). Component 1 được chọn làm nền vì vừa có số lượng pixel lớn nhất, vừa mang đặc trưng màu xanh của vùng cỏ. Các giá trị màu trung bình của các component là: component 0: RGB trung bình xấp xỉ (38.8, 42.7, 27.5); component 1: RGB trung bình xấp xỉ (68.8, 87.9, 47.1); component 2: RGB trung bình xấp xỉ (169.5, 165.5, 143.2).

Nhận xét: cách làm này có ưu điểm là không cần nhãn ảnh thủ công, chỉ dựa vào phân bố màu để tách nền. Tuy nhiên, kết quả phụ thuộc mạnh vào màu sắc của ảnh. Nếu đối tượng chính có màu gần giống nền, hoặc ánh sáng thay đổi nhiều, GMM theo RGB có thể tách chưa chính xác. Để cải thiện, có thể kết hợp thêm thông tin vị trí pixel, chuyển sang không gian màu HSV/Lab hoặc dùng hậu xử lý hình thái học để làm mịn mask.




Hình 5.1. Ảnh gốc



Hình 5.2. Mask đối tượng sau khi lọc nền



Hình 5.3. Ảnh sau khi loại nền



Hình 5.4. Log-likelihood khi train GMM trên ảnh

6. Kết luận chung

Qua năm bài thực hành, có thể thấy K-Means là thuật toán đơn giản và hiệu quả khi dữ liệu có các cụm cân bằng, tách biệt và gần dạng hình cầu. Tuy nhiên, khi dữ liệu bị mất cân bằng kích thước hoặc có cụm kéo dài do covariance khác nhau, K-Means dễ hội tụ về nghiệm chưa tốt vì chỉ tối ưu khoảng cách đến tâm cụm.

GMM khắc phục một phần hạn chế này bằng cách mô hình hóa mỗi cụm như một phân phối Gaussian với covariance riêng. Kết quả ở bài 4 cho thấy GMM phù hợp hơn trong trường hợp cụm có dạng elip. Ở bài 5, GMM còn có thể được dùng cho xử lý ảnh bằng cách xem mỗi pixel là một mẫu dữ liệu trong không gian màu. Dù vậy, GMM cũng nhạy với khởi tạo, số component K và đặc trưng đầu vào, nên trong bài toán thực tế cần kết hợp thêm tiền xử lý và đánh giá trực quan.

Nhìn chung, phần hiện thực OOP giúp chương trình rõ ràng hơn: KMeans, GMM, sinh dữ liệu, trực quan hóa và lọc ảnh được tách thành các module riêng. Cấu trúc này thuận tiện cho việc chạy lại từng bài, kiểm tra kết quả và mở rộng các thí nghiệm tiếp theo.